



(a) oracle 口径: TTFT_{eff} 时延乐观下界



(b) 实际墙钟主指标



(a) 为 oracle 时延乐观下界 (推测收益上界), (b) 为实际墙钟主指标 (最后段到达 $\rightarrow$ 首 token 就绪); 同批九条件 (8 阈值 + 永不推测), 每点 $n=500$ (5 session $\times$ 100 对话)。